ML Course Project Tutorial

1 项目总述

本课程项目围绕视觉-语言大模型（Vision-Language Model, VLM）的微调展开，旨在帮助同学们通过实践掌握从数据收集、数据标注、数据清洗，到模型训练与评测的完整流程。

项目提供两种选择：同学们可以使用课程提供的行人视角空间智能任务及数据，也可以结合自己的专业背景或兴趣方向，自行定义任务、构建数据集，并完成模型训练与实验报告（详见第 3 节）。

2 基于行人视角的空间智能 VLM 训练

2.1 问题背景以及评估测试集

空间智能（Spatial Intelligence）是指智能体感知、理解和推理三维空间环境的能力，包括识别物体的空间位置与几何关系、理解自身及其他物体的运动，以及利用空间信息完成推理与决策等。

行人视角下的空间智能具有广泛的应用价值，例如辅助导航、环境理解和具身智能等。同时，真实的行人视角视频往往涉及复杂的开放场景、持续变化的观察视角以及跨时间的空间信息关联，对模型的空间理解能力提出了较高要求。

在本项目中，我们采用视频问答（Video Question Answering, Video-QA）的形式评估视觉-语言大模型的空间智能能力。模型输入仅包括 RGB 视频和文本问题（Prompt），输出为对应的问题答案。

课程将提供预先标注好的验证集与测试集，用于评估模型的训练效果。视频场景主要涵盖城市步行游览场景，以及商场等大型室内公共空间。问题类型包括物体的几何位置与空间关系感知、自体及其他目标的运动感知，以及简单的空间推理等。

为便于统一评测，本项目不设置开放式文本问答（Open-ended Questions），所有问题均要求输出数值答案或单项选择答案。具体评测方式参考 [1, 2]。

在数据发布方面：

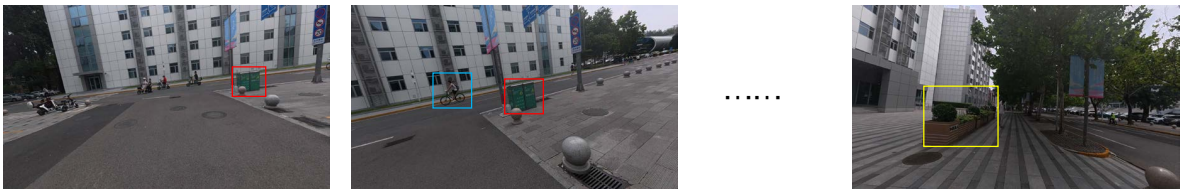
- **验证集：**将通过 Hugging Face 或 ModelScope 公开发布，包含视频、问题及对应答案，供同学们进行模型调试与效果验证。**验证集地址：**（建设中）
- **测试集：**不公开发布，以避免测试数据泄露。课程将在指定的若干时间节点组织统一评测，同学们可提交训练好的模型权重，由后台完成评测并返回结果。

一组典型的视频输入及问题示例如图 1所示。更多问题示例可在公开的验证集中查看。

2.2 数据构建与标注

本项目不会直接提供完整的训练数据集，而是提供部分用于训练的原始 RGB 视频，以及一套基础的数据构建 Pipeline 代码。该 Pipeline 集成了视觉-语言大模型（VLM）、目标检测、深度估计、相机位姿估计等模型，可以从原始视频中自动提取空间信息，并生成部分视频问答训练样本。

视频输入:



示例问题:

1. What is the distance (in meters) between the {rubbish bin visible at 00:15} and the {raised planter visible at 01:45}?

2. What is the speed (in m/s) of the {cyclist visible at 00:18}?

3. How far (in meters) does the camera travel between 00:25 and 01:10?

4. Which of the following best describes the camera's overall trajectory throughout the video?
A. Straight line
B. L-shaped path
C. Z-shaped path
D. Closed loop

图 1: 测试集中相关输入与问题示例。图中标注框仅作指示示意，实际视频输入中无相应指示框，只使用出现时间与文本描述来指代被提问目标。

然而，仅依赖自动化 Pipeline 生成的数据，可能存在标注误差、问题质量不足、数据分布不均衡等问题，未必能够达到理想的模型训练效果。因此，**本项目鼓励同学们自主探索数据构建与标注方法，以提升训练数据的质量和有效性**。

具体而言，同学们可以从数据源选择、问题设计、自动化标注方法、数据清洗与质量验证等方面进行改进。例如，收集具有不同场景特征的视频、设计更有针对性的空间推理问题，或通过额外的模型与人工校验提高标注准确性。

需要注意的是，本项目的不鼓励单纯通过扩大数据规模提升性能。为保证实验的公平性，课程将统一使用相同的基座模型，并限制训练步数，使不同方案之间的主要变量集中于训练数据以及训练策略本身。

标注 Pipeline 仓库:（建设中）

2.3 模型微调与训练

本项目统一使用 **Qwen2.5-VL** 作为基座模型。课程将提供配套的模型微调代码，包括训练数据格式、训练流程及默认超参数等。同学们需要将自行构建的训练数据整理为指定格式，并基于提供的代码完成模型微调。

为保证不同数据方案之间的可比性，课程将统一基座模型、主要训练配置及训练步数。同学们可以开展多组实验，比较不同数据来源、标注方法及数据构成对模型性能的影响，但不鼓励通过修改模型架构或额外增加训练预算来提升成绩。

训练代码仓库:（建设中）

GPU 计算资源:（待学校审批完成后公布）

3 自选主题 VLM 训练

除课程提供的空间智能任务外，同学们也可以结合自身的专业背景或兴趣领域，自主选择研究主题，开展视觉-语言大模型（VLM）或大语言模型（LLM）的微调实践。

与前述项目类似，自选主题同样需要完成从任务定义、数据收集与构建、数据标注与清洗，到模型训练、评测及结果分析的完整流程。同学们可以根据具体任务自主选择基座模型、数据来源和训练方法。

选题要求：在正式开展项目前，请先将拟定的研究主题、任务定义（包括模型输入与输出）、数据来源、初步的数据构建方案以及预期评测方式等基本信息整理成简要说明，通过邮件发送给课程助教进行咨询，以确认选题的可行性及工作量是否合适。

数据构建要求：本项目鼓励同学们围绕所选任务开展具有独立性的探索，例如自主收集数据、设计标注方法、构建新的训练样本，或对已有数据进行针对性的清洗、筛选和改进。可以使用公开数据集作为研究基础，但**如果仅使用现成的公开数据集（off-the-shelf dataset）直接进行模型微调，而缺乏独立的数据构建、方法设计或实验探索，将会影响最终成绩**。

训练与评测：同学们需要根据所选任务设计合理的训练与评测方案，使用独立的验证或测试数据评估模型性能，并尽可能通过对比实验分析所采用的数据构建或训练方法的实际效果。

4 实验报告

项目结束后，同学们需要提交一份简要的实验报告，总结整个项目的实践过程与最终结果。报告应包括任务介绍、数据构建与处理方法、模型训练设置、实验结果及分析等内容。

需要强调的是，**本课程项目并不单纯以模型的最终性能作为评价标准**，而是更加关注同学们在实践过程中开展的探索与思考。报告应重点展示如何发现问题、分析原因、提出改进方案，并通过实验验证改进效果。例如，可以通过多组对比实验，分析不同数据来源、标注方法或数据处理策略对模型性能的影响。

对于未达到预期效果的尝试，也鼓励在报告中进行记录和分析。只要具有合理的实验设计和充分的分析，未能带来性能提升的探索同样具有价值。

最终将综合考虑项目的完整性、独立探索的工作量、实验设计的合理性，以及分析和解决问题的过程，而非仅依据最终模型得分进行评价。

参考文献

[1] Jihan Yang, Shusheng Yang, Anjali W. Gupta, Rilyn Han, Li Fei-Fei, and Saining Xie. Thinking in space: How multimodal large language models see, remember, and recall spaces, 2025. URL https://arxiv.org/abs/2412.14171.

[2] Mingrui Wu, Zhaozhi Wang, Fangjinhua Wang, Jiaolong Yang, Marc Pollefeys, and Tong Zhang. From indoor to open world: Revealing the spatial reasoning gap in mllms, 2025. URL https://arxiv.org/abs/2512.19683.